

# Avaliação da originalidade cromática de aplicativos



## Objetivo

Desenvolver um módulo de avaliação da originalidade cromática de apps usando técnicas clássicas de visão computacional e redes neurais convolucionais.

## Abordagem clássica

## Conjunto de dados




148 Screenshots de aplicativos criados com App Inventor  
- 80% treino  
- 20% validação



- formato png  
- dimensões 1080 x 1920  
- cor RGB

### Extração

Extraí o dicionário de frequência de cores RGB agrupando cores similares com a medida  $\Delta E76$ .



cor	pctg
(255, 255, 255)	65.5%
(100, 149, 237)	35%
(100, 149, 80)	0.01%
...	...

### Transformação

Transforma o espaço de cor RGB para CIE LAB



cor	pctg
(100, 0.0007, 0.0003)	65.5%
(61.9, 9.344, -49.293)	35%
(100, 149, 80)	0.00%
...	...

### Truncamento

Trunca a quantidade (até 10) e porcentagem de cores (maior que 0.1%)

cor	pctg
(100, 0.0007, 0.0003)	65.5%
(61.9, 9.344, -49.293)	35%
(100, 149, 80)	0.00%
...	...

**Otimização combinatória.** Identificação de correspondência par-a-par de cores por meio do algoritmo húngaro usando a métrica  $\Delta E2000$ .

Tela query	
cor	pctg
(100, 0.0007, 0.0003)	65.5%
(61.9, 9.344, -49.293)	35%

Menor  $\Delta E2000$

Tela query	
cor	pctg
(100, 0.0007, 0.0003)	65.5%
(61.9, 9.344, -49.293)	35%

Menor  $\Delta E2000$

Tela comparação 1	
cor	pctg
(50, 13.000, -51.0003)	35.5%
(98.1, 2.000, 0.150)	20%
(40.3, 5.777, 13.010)	8%

Tela comparação 2	
cor	pctg
(98, 0.0107, 0.0044)	70.5%
(61.0, 9.943, -46.242)	25%
...	...

Extração  
Transformação  
Truncamento



Universo de referência

Extração  
Transformação  
Truncamento

\*baseado em sugestões da literatura

### Atribuição do valor de similaridade (query vs. comparação)

$$SIM_{query\ vs.\ comp} = \frac{\sum \{ ((pctg_{query} - pctg_{comp}) * 0.55 + \Delta E2000(cor_{query}, cor_{comp}) * 1.5) * pctg_{query} \}}{0.01}$$

### Interpretação

Entrada: similaridades entre a tela query vs. telas de comparação

Saída: três classes (nada original; mais ou menos original; original)

### Resultados

Classificador	Acurácia
Random Forest	80,00%
Support Vector Classifier	76,67%
Decision Tree Classifier	70,00%
Multinomial Naive Bayes	50,00%

## Abordagem com Deep Learning

### Carregamento de redes pré-treinadas

ResNet34 e ResNet50



### Adaptações e treinamento

Adaptação das camadas de entrada e finais e treinamento com quatro épocas



### Descongelamento e ajuste fino

Encontra a taxa de aprendizagem ótima

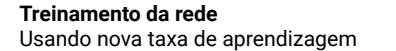
ResNet34

ResNet50

Treino

### Treino da rede

Usando nova taxa de aprendizagem



### Resultados sem ajuste fino

Após quatro épocas	Acurácia
ResNet34	62,06%
ResNet50	75,87%

### Resultados com ajuste fino

Após duas épocas	Acurácia
ResNet34	58,62%
ResNet50	72,42%

## Considerações

- **Resultados.** Técnica clássica apresentou melhores resultados (80,00% vs. 75,87%)

- **Limitações.** Originalidade é um conceito elástico e subjetivo, por isso, para o modelo clássico, optou-se por seguir a definição da literatura baseada em universo de comparação

- **Trabalhos futuros.** Sugere-se ajustar os pesos da atribuição do valor de similaridade na abordagem clássica e/ou trabalhar com modelos híbridos em deep learning

Código: [codigos.ufsc.br/nathalia.alves/visao\\_computacional](https://codigos.ufsc.br/nathalia.alves/visao_computacional)  
Apresentação: <https://youtu.be/bN4kGgpUTJs>